

REPORT HOMEWORK 4 · INDIVIDUAL · Data Science vs PM2.5

PM2.5 in Northern Thailand: from raw data to a recommendation

Name _____Panodbhorn Kongsanguansuk_____ Student ID _____690755904_____

1. ที่มาและความสำคัญของปัญหา

ทุกปีในช่วงประมาณเดือนมกราคมถึงเมษายน คุณภาพอากาศในภาคเหนือของประเทศไทยจะแย่ลงอย่างรุนแรง การเผาเศษวัสดุทางเกษตร ไฟป่า และหมอกควันข้ามพรมแดน ประกอบกับสภาพอากาศที่นิ่งและภูมิประเทศแบบภูเขาที่กักเก็บมลพิษไว้ในหุบเขา ในช่วงเวลานี้ความเข้มข้นของ PM2.5 มักเกินมาตรฐานทั้งของระดับประเทศและระดับสากลอยู่เสมอ ส่งผลให้โรงเรียนต้องปิด จำนวนผู้ป่วยโรคทางเดินหายใจที่เข้ารับรักษาในโรงพยาบาลเพิ่มขึ้น และภาคการท่องเที่ยวได้รับผลกระทบ

จังหวัดเชียงใหม่เคยถูก IQAir จัดอันดับเป็นเมืองที่มีคุณภาพอากาศแย่อันดับ 1 ของโลกหลายครั้งในเดือนมีนาคม 2569 (เช่น วันที่ 30 มีนาคม 2569 ค่า AQI พุ่งสูงถึง 233) ซึ่งตรงกับช่วงเวลาที่ข้อมูลในรายงานนี้ชี้ว่าปี 2569 เป็นปีที่รุนแรงที่สุดในรอบ 4 ปีที่ศึกษาพอดี (ที่มา: IQAir/Nation Thailand, nationthailand.com, 30 มีนาคม 2569)

มาตรฐานคุณภาพอากาศเฉลี่ย 24 ชั่วโมงของประเทศไทยสำหรับ PM2.5 อยู่ที่ 37.5 ไมโครกรัมต่อลูกบาศก์เมตร ($\mu\text{g}/\text{m}^3$) กำหนดโดยกรมควบคุมมลพิษ (PCD) ตามประกาศคณะกรรมการสิ่งแวดล้อมแห่งชาติ ซึ่งมีผลบังคับใช้ตั้งแต่วันที่ 1 มิถุนายน 2566 (ปรับลงจากมาตรฐานเดิมที่ 50 $\mu\text{g}/\text{m}^3$) ค่ามาตรฐานนี้เพียงค่าเดียวเป็นตัวกำหนดว่าจะออกประกาศเตือนภัยหรือไม่ จะต้องดกกิจกรรมกลางแจ้งหรือไม่ และวันนั้นจะถูกนับเป็นวันที่เกินมาตรฐานในสถิติทางการหรือไม่ (ที่มา: กรมควบคุมมลพิษ, pcd.go.th/pcd_news/29901)

การที่ทราบว่าอากาศไม่ดีในช่วงฤดูเผาเป็นเรื่องที่ทราบกันโดยทั่วไปอยู่แล้ว และเพียงแค่นั้นยังไม่ถือเป็นการวิเคราะห์ รายงานฉบับนี้จึงตั้งคำถามที่เจาะจงเอาไว้ 3 ข้อ ได้แก่ ปัญหารุนแรงมากน้อยเพียงใด ที่ใด และเมื่อใด, คุณภาพอากาศของวันถัดไปสามารถทำนายได้แม่นยำพอที่จะใช้เป็นระบบเตือนภัยหรือไม่ และจากหลักฐานที่ได้ผู้มีอำนาจตัดสินใจควรทำอะไรต่อไป เนื้อหาส่วนที่เหลือของรายงานนี้ จะไล่ตอบคำถามทีละข้อ โดยใช้ข้อมูล PM2.5 และสภาพอากาศของ 2 จังหวัดในภาคเหนือ ได้แก่ เชียงใหม่และเชียงราย ดึงมาด้วยสคริปต์ `fetch_data.py` ที่เขียนรายละเอียดวิธีตั้งอยู่ในส่วนที่ 3

2. แนวทางการดำเนินงาน

รายงานฉบับนี้กำหนดกลุ่มเป้าหมายหลักเป็นโรงพยาบาลและผู้วางแผนด้านสาธารณสุข เพื่อนำไปสร้างประโยชน์สู่ประชาชนทั่วไปต่อไป โดยงาน machine learning ใน Part C ถูกวางกรอบไว้ 2 แบบ ได้แก่ แบบ classification (พรั่งนี้ค่าเฉลี่ย

PM2.5 รายวันจะเกินมาตรฐาน Moderate ของ PCD ที่ 37.5 $\mu\text{g}/\text{m}^3$ หรือไม่) และแบบ regression (ค่าเฉลี่ย PM2.5 รายวันของพฤษภาคมจะเป็นเท่าไร) โดยให้ความสำคัญกับแบบ classification เป็นหลัก เพราะเชื่อมโยงตรงกับการตัดสินใจแบบสองทางเลือกที่โรงพยาบาลสามารถนำไปใช้ได้จริง ส่วนแบบ regression ทำเพิ่มเติมเพื่อเปรียบเทียบผลกัน

นอกจากทำนายวันถัดไปแล้ว รายงานนี้ยังดูด้วยว่าวันที่ฝุ่นเกินมาตรฐานมักเกิดติดกันเป็นช่วงๆ เป็นระยะเวลานานเพียงใด โดยเฉพาะว่าช่วงอากาศแยแต่ละครั้งมักยาวกี่วัน และมีบางช่วงที่ยาวผิดปกติจนกลายเป็นปัจจัยหลักที่ทำให้ประชาชนสัมผัสฝุ่นสะสมมากหรือไม่ ประเด็นนี้เป็นที่มาของข้อเสนอแนะใน Part D คือแทนที่จะมองทุกวันที่เกินมาตรฐานเหมือนกันหมดระบบแจ้งเตือนของโรงพยาบาลควรพิจารณาทั้งค่าพยากรณ์ว่าวันถัดไปจะเกินมาตรฐานหรือไม่ และพิจารณาด้วยว่าช่วงอากาศแยที่กำลังเกิดขึ้นในขณะนั้นดำเนินมาแล้วเป็นระยะเวลากี่วัน แล้วนำทั้งสองปัจจัยนี้มาประกอบการตัดสินใจว่าจะแจ้งเตือนกลุ่มผู้ป่วยเพราะบางทีลงทะเยียนไว้ (เช่น ผู้ป่วยโรคทางเดินหายใจเรื้อรัง) เมื่อใด

สิ่งที่คาดการณ์ไว้ก่อนเริ่มทำ

ก่อนเริ่มวิเคราะห์ ได้ตั้งความคาดหวังไว้ 3 ข้อ ข้อแรกคือ PM2.5 น่าจะพุ่งสูงตามฤดูกาลเข้าทุกปีช่วงมกราคม-เมษายนอย่างชัดเจน ข้อสองคือ baseline แบบ persistence (ทำนายว่าค่าของวันถัดไปเท่ากับวันปัจจุบัน) น่าจะมีประสิทธิภาพเหนือกว่าได้ยาก เพราะมลพิษทางอากาศมีความสัมพันธ์กันสูงระหว่างวันที่ติดกัน และข้อสามคือเชิงใหม่กับเชิงรายแม้จะอยู่ใกล้กัน แต่ก็ไม่น่าจะมีลักษณะเหมือนกันทุกประการ คาดว่าจะมีรูปแบบตามฤดูกาลคล้ายกัน แต่ตัวเลขจริงน่าจะมีความแตกต่างกันอยู่บ้าง เมื่อดำเนินการเสร็จแล้ว จะนำผลที่ได้จริงมาเปรียบเทียบกับความคาดหวังไว้ทั้ง 3 ข้อนี้ใน Section 4

3. วิธีการดำเนินงาน

3.1 แหล่งข้อมูล

แหล่งข้อมูล	ตัวแปร	ช่วงเวลา	วัดจริงหรือแบบจำลอง
Open-Meteo Air Quality API	PM2.5, PM10, CO, dust (รายชั่วโมง)	2023-01-01 ถึงปัจจุบัน	แบบจำลอง (Modelled) -- CAMS reanalysis
Open-Meteo Archive API (ERA5)	อุณหภูมิ, ความชื้น, ลม, ฝน, ความกดอากาศ (รายชั่วโมง)	2023-01-01 ถึงปัจจุบัน	แบบจำลอง (Modelled) -- ERA5 reanalysis

ตาราง breakpoint AQI ของ PCD	ค่ามาตรฐาน PM2.5 แบบคงที่	ไม่มี (ตารางอ้างอิง)	ค่ามาตรฐานทางการ (ไม่ใช่ทั้งวัดหรือจำลอง)
Air4Thai (ใช้ใน Checkpoint C6)	PM2.5 ปัจจุบัน จากสถานีภาคพื้น	จุดเวลาปัจจุบันเท่านั้น ไม่มีประวัติ	วัดจริง (Measured) -- เครื่องมือวัดที่สถานี

ข้อมูลจากแหล่งที่ 1 และ 2 เป็นผลลัพธ์จากแบบจำลอง (model output) ส่วนข้อมูลจาก Air4Thai เป็นค่าที่วัดจริงจากเครื่องมือ (instrument) ทั้งสองแบบไม่ใช่สิ่งเดียวกัน ความแตกต่างนี้คือประเด็นสำคัญที่ Checkpoint C3 และ C6 อภิปรายไว้โดยละเอียด

แหล่งข้อมูลแบบ time series ทั้งสองถูกเรียกด้วยฟังก์ชัน ช่วงวันที่ และ timezone เดียวกัน (Asia/Bangkok) ผ่านสคริปต์ที่รันซ้ำได้ (src/fetch_data.py) ซึ่งบันทึกผลลัพธ์ดิบจาก API ทุกครั้งไว้ที่ data/raw โดยไม่แก้ไขก่อนทำความสะอาดข้อมูล ส่วนตาราง breakpoint ของ PCD เป็นข้อมูลอ้างอิงคงที่ (ไม่ได้ดึงจาก API) มาจากประกาศกรมควบคุมมลพิษของประเทศไทย พ.ศ. 2566

หมายเหตุเรื่องการรันซ้ำ: fetch_data.py กำหนดวันที่สิ้นสุดเป็นวันที่ปัจจุบันเสมอ (date.today()) ดังนั้นหากรันสคริปต์นี้ซ้ำในวันที่ต่างไปจากเดิมจะได้ไฟล์ที่มีจำนวนแถวมากกว่าเดิม (มีข้อมูลของวันที่ผ่านมาเพิ่มเข้ามา) ไม่ใช่ไฟล์ชุดเดียวกันทุกประการ นี่เป็นพฤติกรรมที่ตั้งใจออกแบบไว้เพื่อให้ข้อมูลอัปเดตล่าสุดเสมอเมื่อรันใหม่ ไม่ใช่ข้อผิดพลาดของสคริปต์

3.2 การทำความสะอาดและรวมข้อมูล

ขั้นตอนนี้อาจไฟล์ข้อมูลดิบที่ดึงมาได้จาก fetch_data.py มาทำความสะอาดและรวมกันให้พร้อมใช้งาน ผ่านสคริปต์ src/prepare_data.py มีทั้งหมด 3 ขั้นตอนหลัก

ขั้นแรก คือรวมข้อมูลคุณภาพอากาศกับข้อมูลสภาพอากาศเข้าด้วยกัน (join) โดยจับคู่กันด้วยเวลาที่ตรงกันในแต่ละชั่วโมง ทำแยกกันสำหรับเชียงใหม่และเชียงราย เพราะเป็นข้อมูลคนละไฟล์คนละพื้นที่

ขั้นที่สอง คือย่อข้อมูลจากรายชั่วโมงให้เหลือรายวัน (aggregate) เนื่องจากข้อมูลดิบมีความละเอียดระดับชั่วโมง แต่โมเดลและกราฟที่ต่อไปต้องการข้อมูลระดับวัน วิธีย่อขึ้นอยู่กับชนิดของตัวแปร ตัวแปรส่วนใหญ่ เช่น PM2.5 อุณหภูมิ ความชื้น ใช้ค่าเฉลี่ยของ 24 ชั่วโมงในวันนั้น ส่วนปริมาณฝนใช้ผลรวมทั้งวันแทน เพราะฝนควรบวกกันไม่ใช่เฉลี่ยกัน ส่วนทิศทางลมต้องใช้วิธีพิเศษที่เรียกว่า circular mean เพราะทิศทางลมเป็นค่ามุม 0-360 องศา ถ้าเฉลี่ยแบบธรรมดาจะผิด เช่น ลม 350 องศา กับ 10 องศา เฉลี่ยปกติจะได้ 180 องศาซึ่งกลายเป็นทิศตรงข้าม ทั้งที่จริงสองค่านี้ใกล้เคียงกันมาก

ขั้นที่สาม คือเติมวันที่ที่ขาดหายไปให้ครบ (reindex) คือสร้างตารางที่มีทุกวันตามปฏิทินตั้งแต่วันแรกถึงวันสุดท้าย แม้บางวันจะไม่มีข้อมูลเลยก็ตาม เพื่อให้เห็นชัดเจนว่าวันไหนข้อมูลขาดหายไปจริง แทนที่จะซ่อนไว้เฉยๆ โดยไม่รู้ตัว

ผลลัพธ์สุดท้ายที่ได้คือตารางข้อมูลรายวัน รวมทั้งหมด 2,662 แถว (เชียงใหม่กับเชียงรายรวมกัน จังหวัดละ 1,331 แถว) ครอบคลุมตั้งแต่วันที่ 1 มกราคม 2023 ถึง 23 สิงหาคม 2026 รายละเอียดตัวเลขทั้งหมดอยู่ใน Checkpoint C1-C3 ของ Section

3.3 การสร้างฟีเจอร์

หลังจากได้ตารางข้อมูลรายวันแล้ว ขั้นตอนต่อไปคือเลือกและสร้างฟีเจอร์ที่จะป้อนให้โมเดลใช้ทำนาย ฟีเจอร์ทั้งหมดมี 12 ตัว แบ่งออกเป็น 3 กลุ่ม

กลุ่มแรกคือค่ามลพิษทางอากาศเฉลี่ยรายวัน ได้แก่ PM2.5, PM10, คาร์บอนมอนอกไซด์ และฝุ่นทั่วไป กลุ่มนี้เอาไว้บอกว่ในวันนั้นอากาศเป็นอย่างไร

กลุ่มที่สองคือค่าสภาพอากาศเฉลี่ยรายวัน ได้แก่ อุณหภูมิ ความชื้น ความเร็วลม ทิศทางลม ปริมาณฝนสะสม และความกดอากาศ กลุ่มนี้เอาไว้ช่วยอธิบายว่าทำไมมลพิษถึงสูงหรือต่ำ เช่น วันที่ลมสงบฝุ่นมักสะสมมากกว่าวันที่ลมแรง

กลุ่มที่สามคือฟีเจอร์ที่สร้างขึ้นเองเพิ่มเติม ไม่ได้มาจาก API ตรงๆ ได้แก่ ตัวบอกว่าวันนั้นเกินมาตรฐาน Moderate ของ PCD หรือไม่ (ใช่/ไม่ใช่) และตัวนับว่าวันนี้เป็นวันที่กี่ที่เกินมาตรฐานติดต่อกัน สร้างตัวหลังขึ้นมาโดยเฉพาะ เพื่อให้โมเดลมีข้อมูลประกอบด้วยว่าขณะนั้นอยู่ในช่วงอากาศแย่ที่ต่อเนื่องมาเป็นระยะเวลาานเพียงใดแล้ว ซึ่งเชื่อมโยงกับมุมที่เลือกทำในการศึกษานี้คือการดูว่าช่วงอากาศแย่ที่ยาวติดต่อกันส่งผลอย่างไร (รายละเอียดอยู่ใน Section 4)

(ชื่อคอลัมน์จริงในไฟล์ข้อมูลดูได้ที่ data/processed/daily_combined.csv)

3.4 การกำหนดตัวแปรเป้าหมาย

ก่อนสร้างโมเดล ต้องกำหนดให้ชัดก่อนว่าโมเดลจะทำนาย "อะไร" ตาม Section 6 กฎข้อ 1 ของโจทย์ ที่ระบุว่าตัวแปรเป้าหมายต้องเจาะจง จะระบุเพียงคำว่า "ทำนาย PM2.5" โดยไม่เจาะจงรายละเอียดไม่ได้ ต้องระบุให้ชัดจะทำนาย PM2.5 ของวันใด และในรูปแบบใด

การศึกษานี้จึงสร้างตัวแปรเป้าหมายขึ้น 2 ตัว โดยทั้งคู่หมายถึงค่าของ "วันพรุ่งนี้" เทียบกับแถวข้อมูลของ "วันนี้" เสมอ (คือนำฟีเจอร์ของวันปัจจุบันมาใช้ทำนายค่าของวันถัดไป)

ตัวแปรเป้าหมายตัวแรก คือค่าเฉลี่ย PM2.5 รายวันของพรุ่งนี้ หน่วยเป็นไมโครกรัมต่อลูกบาศก์เมตร ($\mu\text{g}/\text{m}^3$) ใช้สำหรับงานแบบ regression คือการทำนายค่าตัวเลขโดยตรง

ตัวแปรเป้าหมายตัวที่สอง คือค่าบอกว่าพรุ่งนี้ค่าเฉลี่ย PM2.5 รายวันจะเกิน $37.5 \mu\text{g}/\text{m}^3$ หรือไม่ (ใช่/ไม่ใช่) ใช้สำหรับงานแบบ classification คือการทำนายผลลัพธ์เป็นสองทางเลือก ซึ่งตรงกับที่บอกไว้ใน Section 2 ว่าเป็นแบบที่ให้ความสำคัญเป็นหลัก เพราะเชื่อมโยงตรงกับการตัดสินใจแจ้งเตือนของโรงพยาบาลได้ทันที

3.5 วิธีการแบ่งข้อมูล Train/Test

ก่อนฝึกโมเดล ต้องแบ่งข้อมูลออกเป็นสองส่วนคือ ส่วนที่ใช้สอนโมเดล (train) กับส่วนที่ใช้ทดสอบว่าโมเดลทำนายได้แม่นยำมากน้อยเพียงใด (test) โดยห้ามให้โมเดลเห็นข้อมูลส่วน test มาก่อนตอนเทรนเด็ดขาด

ข้อมูลของงานนี้เป็น time series คือเรียงตามเวลา จึงแบ่งด้วยการตัดตามช่วงเวลาแทนการสุ่มแบ่งแบบทั่วไป เพราะถ้าสุ่มแบ่ง อาจมีข้อมูลของอนาคตหลุดเข้าไปอยู่ในชุด train ทำให้โมเดลได้เปรียบเกินจริง

วิธีที่ใช้คือเก็บ 20% ของวันตามปฏิทินที่ล่าสุดไว้เป็น test set นั่นคือตั้งแต่วันที่ 30 พฤศจิกายน 2025 เป็นต้นไป ส่วนที่เหลือก่อนหน้านี้เป็น train และกำหนดให้ทั้งเชิงใหม่และเชิงราย้ใช้จุดตัดวันที่เดียวกันอย่างเคร่งครัด เพื่อไม่ให้ข้อมูลของจังหวัดหนึ่งในวันอนาคตหลุดเข้าไปปนกับข้อมูลของอีกจังหวัดในชุด train ได้ข้อมูล train ทั้งหมด 2,128 แถว และ test 532 แถว

นอกจากนี้ ระหว่างที่ปรับแต่งโมเดลบนชุด train ก็ต้องมีวิธีตรวจสอบว่าโมเดลมีประสิทธิภาพมากน้อยเพียงใดโดยไม่ตะต้องชุด test เลย จึงใช้วิธี cross-validation ที่เรียกว่า expanding window แบ่งตามวันที่ (แนวคิดเดียวกับ TimeSeriesSplit

ของ scikit-learn) คือแบ่งชุด train ออกเป็น 5 ช่วงย่อยตามลำดับเวลา แล้วขยายขนาดช่วงข้อมูลที่ใช้ฝึกโมเดลไปที่ละรอบ ทดสอบกับช่วงถัดไปที่ยังไม่เคยเห็น ทำเช่นนี้เพื่อจำลองสถานการณ์จริงที่โมเดลต้องคาดการณ์อนาคตจากอดีตเท่านั้น และให้ทั้งสองจังหวัดที่มีวันที่ตรงกันอยู่ในช่วงเดียวกันเสมอ

3.6 โมเดลและ Baseline

ก่อนจะประเมินว่าโมเดลที่สร้างขึ้นมีประสิทธิภาพดีหรือไม่ จำเป็นต้องมีตัวเปรียบเทียบก่อนว่าดีกว่าวิธีการอย่างง่ายมากน้อยเพียงใด ตัวเปรียบเทียบนี้เรียกว่า baseline

Baseline หลักที่ใช้คือ persistence คือทำนายค่าหรือคลาสของวันถัดไปจะเท่ากับของวันปัจจุบันทุกประการ ซึ่งเป็น baseline ที่เหมาะกับข้อมูล time series ตามที่ Section 6 ของโจทย์กำหนดไว้ เพราะมลพิษทางอากาศมักต่อเนื่องกันวันต่อวัน อยู่แล้ว นอกจากนี้ยังมี baseline รองไว้เปรียบเทียบเพิ่มเติมอีก 2 ตัว คือ majority class (ทำนายคลาสที่พบบ่อยที่สุดเสมอสำหรับงาน classification) และ training mean (ทำนายค่าเฉลี่ยของชุด train เสมอ สำหรับงาน regression)

ส่วนโมเดลจริงที่ใช้ คือ Random Forest (RandomForestClassifier สำหรับงาน classification และ RandomForestRegressor สำหรับงาน regression) เลือกใช้ตัวนี้เพราะรองรับความสัมพันธ์แบบไม่เป็นเส้นตรงระหว่างฟีเจอร์ได้ดี เช่น ผลของลมต่อ PM2.5 อาจไม่ได้เป็นเส้นตรงเสมอไป และไม่ต้องปรับสเกลข้อมูลก่อนใช้งาน (feature scaling) เหมือนโมเดลบางแบบ ทำให้ใช้งานง่ายกว่า

สำหรับ metric ที่ใช้วัดผล งาน classification เลือกดู recall ของคลาส exceed เป็นหลัก แทนที่จะดู accuracy อย่างเดียว เพราะข้อมูลไม่สมดุลกัน คือมีวันที่เกินมาตรฐานเป็นส่วนน้อยเมื่อเทียบกับวันปกติ ถ้าพิจารณาแค่ accuracy โมเดลอาจทำนายว่า "ไม่เกินมาตรฐาน" อยู่ตลอดแล้วได้ accuracy สูงที่ค่าเคลื่อนไปจากความจริง ทั้งที่พลาดแจ้งเตือนวันอันตรายไปทั้งหมด ส่วนงาน regression วัดผลด้วย MAE, RMSE และ R^2 ตามมาตรฐานทั่วไปของงานทำนายค่าตัวเลข


3.7 ปัญหาคุณภาพข้อมูลที่พบและแก้ไข กับข้อจำกัดที่ยังแก้ไขไม่ได้

ปัญหาที่พบและแก้ไขแล้ว: ทิศทางลม (wind direction) เป็นตัวแปรเชิงมุม (0-360 องศา) ซึ่งหาค่าเฉลี่ยแบบเลขคณิตปกติไม่ได้ ตัวอย่างเช่น ค่าเฉลี่ยเลขคณิตของ 350° กับ 10° จะได้ 180° ซึ่งผิดหลักภูมิศาสตร์โดยสิ้นเชิง (ทิศทางที่ถูกต้องควรใกล้เคียง $0^\circ/360^\circ$ ไม่ใช่ทิศตรงข้าม) ในขั้นตอน aggregate ข้อมูลจากรายชั่วโมงเป็นรายวัน (prepare_data.py) จึงตรวจพบปัญหานี้ตั้งแต่ต้น และแก้ไขด้วยการใช้ circular mean (แปลงเป็น sin/cos ก่อนหาค่าเฉลี่ยแล้วแปลงกลับเป็นองศา) แทนค่าเฉลี่ยเลขคณิตทั่วไป


ข้อจำกัดที่ยังแก้ไขไม่ได้: จาก Checkpoint C6 พบว่าค่าจากแบบจำลอง Open-Meteo ต่ำกว่าค่าที่วัดจริงจาก Air4Thai อย่างสม่ำเสมอ (66-72% ที่จุดเปรียบเทียบเดียวที่มีข้อมูล) เนื่องจากมีข้อมูลเปรียบเทียบได้เพียง 1 จุดเวลานอกฤดูฝุ่น จึงไม่สามารถแก้ไขความเอนเอียง (bias) นี้ด้วยวิธีทางสถิติได้อย่างมั่นใจในขอบเขตของโครงการนี้ ขอรายงานไว้อย่างเปิดเผยเป็นข้อจำกัด ไม่ใช่สิ่งที่ปิดบังหรือแก้ไขแบบเดา

4. ผลการวิเคราะห์


4.1 กราฟและผลลัพธ์เชิงภาพ




รูปที่ 1: PM2.5 รายวันตามช่วงเวลา เปรียบเทียบเชียงใหม่กับเชียงราย (2023-2026) PM2.5 พุ่งสูงเกินมาตรฐาน PCD อย่างชัดเจน ทุกฤดูหนาวช่วงมกราคม-เมษายนในทั้งสองจังหวัด แล้วลดลงมาอยู่ในระดับต่ำตลอดช่วงที่เหลือของปี



รูปที่ 2: จำนวนวันที่เกินมาตรฐานต่อปี แยกตามพื้นที่ จำนวนวันที่เกินมาตรฐานไม่ได้เพิ่มขึ้นแบบเส้นตรง -- ปี 2024 ลดลงอย่างชัดเจนในทั้งสองจังหวัด แต่ปี 2025 และ 2026 กลับพุ่งขึ้นสูงสุดในรอบ 4 ปี โดยปี 2026 สูงกว่าทุกปีก่อนหน้าแล้ว ทั้งที่ฤดูฝุ่นหลักผ่านไปแล้ว ณ ตอนที่เก็บข้อมูล



รูปที่ 3: การกระจายตัวของ PM2.5 รายวัน แยกตามพื้นที่ เชียงใหม่และเชียงรายมีการกระจายตัวของ PM2.5 ที่แตกต่างกันอย่างมีนัยสำคัญทางสถิติ (Welch's t-test, $p < 0.001$) โดยค่ามัธยฐานของเชียงใหม่สูงกว่าเชียงรายประมาณ 5-6 $\mu\text{g}/\text{m}^3$



รูปที่ 4: ความยาวของช่วงอากาศแย่ (จำนวนวันติดต่อกันที่เกินมาตรฐาน) เชียงใหม่มี 37 ช่วง ยาวที่สุด 17 วัน เฉลี่ย 4.4 วันต่อช่วง ส่วนเชียงรายมีเพียง 28 ช่วงแต่ยาวที่สุดถึง 33 วัน เฉลี่ย 6.5 วันต่อช่วง กล่าวคือเชียงรายเจอช่วงอากาศแย่บ่อยน้อยกว่า แต่เมื่อเกิดขึ้น มักยาวนานและรุนแรงกว่าเชียงใหม่อย่างชัดเจน

4.2 ผลลัพธ์โมเดลเทียบกับ Baseline

งาน	Baseline (persistence)	โมเดล (Random Forest)
Classification (recall ของคลาส exceed)	0.854	0.854 (เท่ากันทุกประการ)
Regression (MAE, $\mu\text{g}/\text{m}^3$)	4.69	4.55

สำหรับงาน classification โมเดล Random Forest ได้ค่า accuracy, precision, recall และ confusion matrix เหมือนกับ baseline persistence ทุกตัวเลข กล่าวได้ว่าโมเดลไม่ได้ให้ผลลัพธ์ที่ดีกว่า baseline เลยในทางปฏิบัติ คำอธิบายที่เป็นไปได้คือฟีเจอร์ที่บอกว่าวันนี้เกินมาตรฐานหรือไม่ (ซึ่งเป็นตัวแปรเดียวกับที่ baseline persistence ใช้โดยตรง) น่าจะเป็นตัวทำนายที่แรงที่สุดอยู่แล้ว ทำให้โมเดลเรียนรู้ไปในทิศทางเดียวกับ persistence โดยไม่ได้เพิ่มความแม่นยำขึ้นมาอีก ส่วนงาน regression โมเดลทำได้ดีกว่า baseline เล็กน้อย (MAE ลดลงประมาณ 3%) ถือเป็นการปรับปรุงที่แท้จริงแต่ไม่มาก

4.3 ตอบคำถาม checkpoint (ตาม Section 7)

C1 : เวลา

ในขั้นตอนดึงข้อมูล ได้กำหนดพารามิเตอร์ timezone=Asia/Bangkok ให้กับทั้งสอง API ตั้งแต่นั้น ดังนั้น timestamp ที่ได้มาจึงเป็นเวลาไทยท้องถิ่นอยู่แล้ว ไม่จำเป็นต้องแปลงเพิ่มเติม ตรวจสอบความถูกต้องด้วยการเช็คระยะห่างระหว่างแต่ละแถว พบว่าห่างกันคงที่ 1 ชั่วโมงตลอดทั้ง 31,944 แถว ไม่มีช่วงใดขาดหายไป จากนั้นได้เปรียบเทียบชุด timestamp ของทั้งสอง API พบว่าตรงกันทั้งหมด 100% ไม่มีจุดใดที่ปรากฏในฝั่งหนึ่งแต่ขาดหายในอีกฝั่ง ทั้งสำหรับเชียงใหม่และเชียงราย

C2 : การรวมข้อมูล (Join)

ข้อมูลจากทั้งสองแหล่ง (air quality และ weather) มีจำนวน 31,944 แถวต่อจังหวัดเท่ากันตั้งแต่ก่อน join เมื่อทำการ join ด้วย timestamp แล้ว ยังคงได้ 31,944 แถวเท่าเดิม ไม่มีแถวใดสูญหายไป เนื่องจากการดึงข้อมูลทั้งสอง API ใช้พิกัด ช่วงวันที่ และ timezone เดียวกันทุกประการ ทำให้เส้นเวลารายชั่วโมงของทั้งสองแหล่งตรงกันตั้งแต่ต้น วิธีตรวจสอบว่าจำนวนแถวไม่เปลี่ยน

จริง คือหาผลต่างระหว่างชุด timestamp ของทั้งสองแหล่งโดยตรง (index difference ทั้งสองทิศทาง) ได้ผลลัพธ์เท่ากับ 0
รายการทั้งคู่ ยืนยันว่าไม่มี timestamp ใดตกหล่นไปจากอีกฝั่งเลย

C3 : ค่าที่ขาดหาย (Missing values)

จากการตรวจสอบพบว่าทุกคอลัมน์มีค่า missing 0.00% ทั้งในระดับรายชั่วโมงและหลังจาก aggregate เป็นรายวัน อย่างไรก็ตาม
ขอพิจารณาประเด็นนี้เป็นข้อจำกัดมากกว่าข้อดี เนื่องจากข้อมูลทั้งหมดมาจาก Open-Meteo ซึ่งเป็นผลลัพธ์จากแบบจำลอง
reanalysis (CAMS สำหรับคุณภาพอากาศ และ ERA5 สำหรับสภาพอากาศ) มีค่าที่ได้จากการวัดด้วยเครื่องมือจริง แบบจำลอง
เชิงตัวเลขจะคำนวณค่าประมาณให้ครบทุกพิกัดและทุกชั่วโมงโดยธรรมชาติของมันเอง จึงไม่มีโอกาสเกิด missing values ใน
ลักษณะที่เซนเซอร์จริงประสบ เช่น ไฟฟ้าขัดข้องหรือความผิดพลาดของอุปกรณ์ ดังนั้นอัตรา missing 0% ที่พบจึงสะท้อนถึง
ลักษณะของแหล่งข้อมูล มิใช่การยืนยันว่าไม่มีปัญหาด้านคุณภาพข้อมูลในสถานการณ์จริง ซึ่งเป็นเหตุผลสำคัญที่ทำให้
Checkpoint C6 มีความสำคัญอย่างยิ่งต่อโครงการนี้

C4 : การเปรียบเทียบพื้นที่

ค่าเฉลี่ย PM2.5 รายวันของเชียงใหม่อยู่ที่ 22.18 $\mu\text{g}/\text{m}^3$ (SD=12.30, n=1,331) เทียบกับเชียงรายที่ 19.76 $\mu\text{g}/\text{m}^3$ (SD=16.20, n=1,331) ผลการทดสอบ Welch's t-test ได้ $t=4.342$, $p=0.000015$ จึงสรุปได้ว่าค่าเฉลี่ยของทั้งสองพื้นที่แตกต่างกันอย่างมี
นัยสำคัญทางสถิติที่ระดับ 5% ที่น่าสนใจคือแม้เชียงรายจะมีค่าเฉลี่ยต่ำกว่า แต่มีค่าเบี่ยงเบนมาตรฐานสูงกว่า (16.20 เทียบกับ
12.30) และเมื่อดูช่วงอากาศแย่ (bad-air episode) เชียงรายมีจำนวนช่วงน้อยกว่าเชียงใหม่ (28 เทียบกับ 37 ช่วง) แต่ช่วงที่
เกิดขึ้นยาวนานกว่ามาก (ยาวที่สุด 33 วัน เฉลี่ย 6.5 วัน เทียบกับเชียงใหม่ที่ยาวที่สุด 17 วัน เฉลี่ย 4.4 วัน) กล่าวคือเชียงรายเจอ
วันอากาศดีบ่อยกว่า แต่เมื่อเกิดเหตุการณ์เลวร้ายจะรุนแรงและยาวนานกว่าเชียงใหม่อย่างชัดเจน ดูการกระจายตัวได้ในรูปที่ 3
และความยาวช่วงอากาศแย่ได้ในรูปที่ 4

C5 : โมเดลเทียบกับ Baseline

บน test set เดียวกัน (532 แถวล่าสุด) โมเดล classification ได้ recall ของคลาส exceed = 0.854 ซึ่งมีค่าเท่ากับ baseline
persistence ในทุกตัวเลข (accuracy, precision, recall, confusion matrix เหมือนกันหมด: TN=422, FP=14, FN=14, TP=82) กล่าวคือโมเดลไม่ได้ให้ความแม่นยำเพิ่มขึ้นจาก baseline ในทางปฏิบัติแต่อย่างใด ส่วนโมเดล regression ได้
MAE=4.55 ตีกว่า baseline persistence ที่ 4.69 อยู่เล็กน้อย (~3%) ถือเป็นการปรับปรุงจริงแต่ไม่มาก อีกจุดที่ต้องอธิบายคือ
คะแนน cross-validation กับคะแนน test ต่างกันมาก (CV recall เฉลี่ย 0.228 เทียบกับ test recall 0.854 ต่างกันเกิน 0.10
ตามที่กำหนดไว้) สาเหตุน่าจะมาจากสัดส่วนวันที่เกินมาตรฐานในชุด train (8.6%) กับ test (18.0%) ต่างกันค่อนข้างมาก
เนื่องจากช่วง test คือฤดูฝนล่าสุด (ปลายปี 2025 ถึง 2026) ซึ่งจาก Fig02 ทราบอยู่แล้วว่ารุนแรงที่สุดในรอบ 4 ปี ทำให้ fold

ต่างๆ ตอนทำ cross-validation (ซึ่งดึงจากช่วงเวลาก่อนหน้าที่เขาบางกว่า และมีตัวอย่างวันเกินมาตรฐานน้อยกว่ามาก) ประเมิน recall ได้ไม่แม่นยำเมื่อเทียบกับสถานการณ์จริงในช่วง test

C6 : การเทียบกับข้อมูลจริง (Ground truth)

เนื่องจาก Air4Thai ไม่มี endpoint ประวัติย้อนหลัง การเปรียบเทียบนี้จึงเป็นการเทียบแบบจุดเดียวในเวลา (snapshot) ไม่ใช่การตรวจสอบแบบ time series ที่สถานี Yupparaj Wittayalai School (ใกล้เชียงใหม่ที่สุด ห่าง 0.6 กม.) เมื่อเวลา 17:00 น. ของวันที่ 23 สิงหาคม 2569 Air4Thai วัดได้ PM2.5 = 9.6 $\mu\text{g}/\text{m}^3$ ขณะที่ Open-Meteo ประมาณค่าไว้ที่ 3.3 $\mu\text{g}/\text{m}^3$ ต่างกัน 6.3 $\mu\text{g}/\text{m}^3$ (66%) ในทำนองเดียวกัน ที่สถานีใกล้เชียงใหม่ Air4Thai วัดได้ 9.0 $\mu\text{g}/\text{m}^3$ เทียบกับ Open-Meteo ที่ 2.5 $\mu\text{g}/\text{m}^3$ ต่างกัน 6.5 $\mu\text{g}/\text{m}^3$ (72%) แม้ผลต่างเป็นเปอร์เซ็นต์จะสูง แต่ต้องตีความอย่างระมัดระวัง เพราะช่วงเวลาที่เก็บข้อมูลเป็นช่วงนอกฤดูฝุ่น ค่า PM2.5 จริงอยู่ในระดับต่ำมากทั้งสองแหล่ง ทำให้ผลต่างสัมบูรณ์เพียง 6-7 $\mu\text{g}/\text{m}^3$ กลายเป็นเปอร์เซ็นต์ที่สูงเกินจริงเมื่อเทียบกับฐานที่มีค่าน้อย ข้อสังเกตที่สำคัญกว่าคือ Open-Meteo ประเมินค่าต่ำกว่าความเป็นจริงในทั้งสองจุดที่เทียบไปในทิศทางเดียวกัน ซึ่งหากรูปแบบนี้เกิดขึ้นในช่วงฤดูฝุ่นด้วย หมายความว่าตัวเลขทั้งหมดในรายงานนี้อาจต่ำกว่าสถานการณ์จริง ข้อจำกัดนี้ควรถูกทดสอบซ้ำในช่วงฤดูฝุ่นจริงก่อนนำข้อเสนอแนะไปใช้งานจริง ระหว่างสองแหล่งนี้ ควรถือว่า Air4Thai เป็นค่าที่ "ถูกต้อง" กว่า เพราะวัดจากเครื่องมือจริงที่ติดตั้ง ณ สถานี ในขณะที่ Open-Meteo เป็นเพียงผลลัพธ์จากแบบจำลอง ผลกระทบต่อข้อสรุปของโครงการนี้คือ ตัวเลข PM2.5 ที่รายงานไว้ทั้งหมดควรถูกมองว่าเป็นค่าประมาณขั้นต่ำของความรุนแรงที่แท้จริง

5. สรุปผลและข้อเสนอแนะ

สิ่งที่ค้นพบ

PM2.5 ทั้งในเชียงใหม่และเชียงรายพุ่งสูงเกินมาตรฐาน PCD ของไทยอย่างชัดเจนทุกฤดูแล้ง โดยจำนวนวันที่เกินมาตรฐานกลับมาเพิ่มขึ้นอีกครั้งในปี 2025-2026 หลังจากลดลงชั่วคราวในปี 2024 ทั้งสองจังหวัดแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ($p < 0.001$) โดยเชียงใหม่มีค่าเฉลี่ยสูงกว่า แต่เชียงรายกลับมีช่วงอากาศแยที่ยาวนานและรุนแรงกว่าเมื่อเกิดขึ้น (ยาวสุด 33 วัน เทียบกับ 17 วันของเชียงใหม่) ด้านโมเดลทำนาย พบข้อค้นพบที่สำคัญคือโมเดล Random Forest สำหรับงาน classification ไม่ได้ให้ความแม่นยำเพิ่มขึ้นจาก baseline persistence เลยแม้แต่น้อย ในขณะที่งาน regression ทำได้ดีกว่า baseline เพียงเล็กน้อย ข้อค้นพบนี้ชี้ให้เห็นว่าความสัมพันธ์เชิงเวลาแบบวันต่อวันเป็นตัวขับเคลื่อนหลักของความสามารถในการทำนาย สุดท้ายการเทียบกับข้อมูลสถานีจริงของ Air4Thai พบว่า Open-Meteo ประเมินค่าต่ำกว่าความเป็นจริงในทั้งสองพื้นที่ ซึ่งเป็นสัญญาณเตือนว่าตัวเลขทั้งหมดในรายงานนี้อาจต่ำกว่าสถานการณ์จริง

ข้อเสนอแนะ

จากผลลัพธ์ที่ได้ ขอเสนอให้โรงพยาบาลที่ให้บริการพื้นที่เชียงใหม่และเชียงราย จัดทำระบบแจ้งเตือนแบบมีระดับขั้นสำหรับทะเบียนผู้ป่วยกลุ่มเปราะบางที่ลงทะเบียนไว้ (โรคทางเดินหายใจเรื้อรัง ผู้สูงอายุ เด็กเล็ก) โดยใช้กฎง่ายๆ ที่อิงจาก

persistence ร่วมกับจำนวนวันติดต่อกันที่เกินมาตรฐานในปัจจุบัน แทนที่จะลงทุนสร้างโมเดล machine learning ที่ซับซ้อน เนื่องจากผลการทดลองแสดงให้เห็นว่ากฎ persistence แบบง่ายให้ความแม่นยำเทียบเท่ากับ Random Forest ทุกประการ การใช้กฎง่ายมีข้อดีเพิ่มเติมคือโปร่งใส ตรวจสอบได้ และไม่ต้องบำรุงรักษาโมเดลในระยะยาว ระบบควรยกระดับการแจ้งเตือนเมื่อจำนวนวันติดต่อกันที่เกินมาตรฐานมากกว่า 3-4 วัน และยกระดับสูงสุดเมื่อเกิน 1 สัปดาห์ จากอัตราการพลาดเตือนที่ 14 จาก 96 วันที่เกินมาตรฐานจริงในชุดทดสอบ (ประมาณ 15%) โรงพยาบาลควรมีแผนสำรองสำหรับวันที่ระบบพลาดเตือนด้วย นอกจากนี้ Checkpoint C6 พบว่า Open-Meteo มีแนวโน้มประเมินค่าต่ำกว่าความเป็นจริง จึงแนะนำให้ตั้งเกณฑ์แจ้งเตือนไว้ต่ำกว่ามาตรฐาน $37.5 \mu\text{g}/\text{m}^3$ เล็กน้อย (เช่น $30\text{--}32 \mu\text{g}/\text{m}^3$) เพื่อชดเชยความเอนเอียงนี้ไว้ก่อน จนกว่าจะมีการยืนยันด้วยข้อมูลสถานีจริงในช่วงฤดูฝุ่น

ข้อจำกัดและแนวทางในอนาคต

การวิเคราะห์หิ้งฟ้าข้อมูลคุณภาพอากาศและสภาพอากาศจากแบบจำลองเป็นหลัก การเทียบกับข้อมูลสถานีจริงของ Air4Thai ทำได้เพียง 1 จุดเวลานอกฤดูฝุ่น และพบว่า Open-Meteo ประเมินค่าต่ำกว่าความเป็นจริงทั้งสองพื้นที่ จึงยังสรุปแน่ชัดไม่ได้ว่ารูปแบบนี้จะเกิดซ้ำในช่วงฤดูฝุ่นหรือไม่ การศึกษานี้ยังครอบคลุมเพียง 2 พื้นที่และข้อมูลประมาณ 3.5 ปีเท่านั้น หากมีเวลามากกว่านี้ การเก็บข้อมูล Air4Thai แบบต่อเนื่องด้วยตนเองในช่วงฤดูฝุ่นจริง ข้อมูลจุดความร้อนจากดาวเทียม (NASA FIRMS) และจังหวัดเพิ่มเติม จะช่วยเพิ่มความน่าเชื่อถือทั้งของโมเดลทำนายและข้อเสนอแนะที่ได้

Submission Checklist

- [✓] Repository is public, or the instructor has been added as a collaborator
- [✓] README.md explains how to run everything, in order
- [✓] requirements.txt lists the packages actually used
- [✓] Cloned into a fresh folder and re-ran everything; it worked
- [✓] data/raw/ contains exactly what the API returned
- [✓] All figures exist as separate files in outputs/figures/
- [✓] Model metrics saved in outputs/results/
- [✓] Report follows the required structure and is a PDF
- [✓] All six checkpoints from Section 7 answered in the report
- [✓] Baseline score reported alongside model score
- [✓] Recommendation names a specific audience

[✓] AI disclosure table completed

[✓] I can explain every line of code I submitted

การเปิดเผยการใช้ AI

ใช้ตรงไหน	สิ่ง/ถามอะไรไป	แก้ไขหรือปฏิเสธอะไรบ้าง
src/fetch_data.py	ช่วยเขียนสคริปต์ในการดึงข้อมูล PM2.5 และสภาพอากาศจาก Open-Meteo สำหรับเชียงใหม่และเชียงราย	ไม่มีการแก้ไข แต่รันทดสอบเองในเครื่องก่อนเชื่อผลลัพธ์
src/prepare_data.py	ให้ช่วยเช็คสคริปต์ในการทำ join/clean/aggregate และดูปรับแก้รายละเอียดเพิ่มเติม	ตรวจสอบตัวเลขที่ได้ (จำนวนแถว, % missing) เทียบกับที่คาดไว้เองก่อนนำไปใช้ในรายงาน
src/analyse.py	ช่วยเขียนสคริปต์ในการสร้างกราฟต่างๆ	ดูกราฟจริงที่ได้แล้วเขียนคำอธิบาย/ตีความเอง
src/model.py	ให้เขียนโมเดล baseline และ Random Forest สำหรับ classification และ regression ให้	พบว่าโค้ดฉบับแรกมี bug ในการคำนวณ baseline persistence ให้ Claude ตรวจสอบและแก้ก่อนเชื่อผลลัพธ์
src/compare_ground_truth.py	ให้ช่วยแนะนำการเขียนสคริปต์ในการดึงข้อมูลจาก Air4Thai มาเปรียบเทียบกับ Open-Meteo	ไม่มีการแก้ไข
README.md	ให้ช่วยดูเขียนคำอธิบายและวิธีรันโค้ดบางส่วน	ไม่มีการแก้ไข